強化学習を用いた三相系統連系インバータ用制御器の設計

Abstract（要旨）

本論文は、強化学習（RL）を用いた電圧形インバータ（VSI）用の制御器設計手法を提案する,。提案する制御器は、RL深層決定論的方策勾配（RL-DDPG）アルゴリズムに基づいており、正確なシステムモデルの知識なしに、アクター・クリティック構造によってオンラインで自律的に制御ゲインを更新する。従来の制御器にはモデルへの依存性や、定常（SS）精度と動的応答性の間の不十分な妥協といった問題があり、制御ゲインの調整が複雑になっていた。本研究ではRL-DDPGエージェントのトレーニング、テスト、および検証が行われる,。この手法を制御システムに実装することで、ロバストな制御のための補正信号を提供でき、定常偏差、リプル、および全高調波歪（THD）を最小化する上で優れた性能をもたらす。シミュレーションを通じて、RL-DDPG制御器の動的および定常性能を従来の比例積分（PI）制御と比較した。シミュレーション結果は、THDの低減と電流追従性能の向上を示している。
キーワード：強化学習（RL）、ニューラルネットワーク、電圧形インバータ、モデルフリー制御、DDPGアルゴリズム、アクター・クリティック、PI制御器。

I. INTRODUCTION（序論）

電圧形インバータ（VSI）は、再生可能エネルギー源を電力網（グリッド）に統合し、交流負荷に電力を供給するために広く使用されている。高調波成分を効果的に低減しつつ優れた出力応答を達成するには、VSIを調整するための適切な制御手法が必要である。従来、マイクログリッドで使用されるインバータは、系統連系時には電流源として機能し、自立運転時には電圧源として機能する,。現在、マイクログリッドにおけるインバータの主流な構成は、系統に供給される電流を管理する電流制御器で補完された電圧形インバータのトポロジーである。電流制御型インバータは、瞬時電流の正確な制御、ピーク電流からの保護、および優れた動的応答など、いくつかの利点を提供する。VSIの有効性は、採用される電流制御手法の質に大きく依存する。電力品質基準を満たすために、インバータは高調波を排除する強力な能力を備えていなければならない,。

これまでに、比例積分（PI）、比例共振（PR）、デッドビート（DB）、ヒステリシス制御など、さまざまな電流制御戦略が提案されている。古典的なPI制御器はVSIの制御に広く利用されてきた。それにもかかわらず、PI制御器のゲインを調整する現在のアプローチは依然としてシステムモデルのパラメータの知識を必要としており、システムパラメータの変動に対するPI制御器の脆弱性を浮き彫りにしている,。さらに、大半のPI制御器はすべての動作条件において一定の制御ゲインを利用している。こ

の柔軟性のなさは、システムの動作条件における大幅な変化が目標とする出力に影響を与える可能性があることを意味する。また、定常状態と過渡状態の制御性能のバランスをとることには本質的な難しさもある。

PR制御方式は、定常偏差を排除しつつ正弦波信号を効果的に調整できるため人気がある。しかし、これもシステムモデルに基づいて調整された一定の制御器ゲインを使用している,。共振制御器の最高の性能を得るためには、制御器の共振周波数が系統周波数と一致している必要がある。したがって、電力網内で検出される系統周波数の変動に応じて、制御器の周波数を適応的に調整する必要がある。

DB予測制御は電流誤差補償に一般的に採用され、電流制御型VSIに高い性能を提供する。しかし、その制御アクションはシステムモデルに基づいて直接計算されるため、DB制御はシステムパラメータの変動に非常に敏感になる,。ヒステリシス制御は、システムを管理するための直接的なアプローチを提供し高速な応答をもたらすが、スイッチング周波数が高く可変になることが多く、その結果、電流リプルが増加し、電流品質が低下し、出力フィルタの設計に課題が生じる。固定のスイッチング周波数を達成するには、特に適応帯域ヒステリシス制御器を採用する場合、制御器の複雑さを増す必要がある。

モデル予測制御（MPC）は、指定された時間枠にわたる変数のその後の挙動を予測するためにシステムモデルを必要とするが、電力変換器の制御における応用は限られている,。これは主に、オンラインでの最適化問題に対処するための膨大な計算要件によるものであり、変換器制御で通常採用される短いサンプリング時間とは相容れない特徴である。

モデルへの依存、動的性能と定常（SS）性能の間の妥協、制御器ゲイン調整の複雑さといった既存の制御手法がもたらす課題に対処するために、本論文ではRL-DDPGアルゴリズムに基づく強化学習制御器を導入する,。近年、多くの研究者が人工知能（AI）や機械学習（ML）を用いた新しいインテリジェント制御技術を提案している。ファジィ論理制御は、ファジィ集合論への依存を通じて不確実な入力を持つ複雑なシステムを処理する上で利点を提供するが、その主観的な性質、ルールベースのサイズ、パラメータ調整の要件、計算の複雑さ、および統合の課題により、ファジィルールの設計と実装は困難になる可能性がある,。ニューラルネットワーク（NN）ベースの制御器の主な欠点は教師あり学習への依存にあり、これにはトレーニング用の大量のラベル付きデータが必要となる,。さらに、これらの制御器は環境やタスク要件の変化に対応するために新しいデータでの再トレーニングを通常必要とするため、オンラインで適応して学習する能力を欠いている可能性がある,。一方、RL-DDPG制御器は、アクションと報酬を通じた環境との直接的な相互作用による経験から学習することができる。RL-DDPGのトレーニングは制御器とシステム間の相互作用に依存しており、オフラインのデータセットを必要としない。

II. SYSTEM MODELLING（システムモデリング）

系統連系インバータは、電力を系統に送る役割を担う基本的なコンポーネントである。一般に、システム全体の安定性を研究し制御器を設計するためには、その動的挙動を評価するためにインバータの動的モデルを持つことが不可欠である,。図1は、RL-DDPG制御器を備えた系統連系三相（$3-\phi$）VSIの構成を示している。式(1)〜(6)は、出力インダクタ電圧$u_{L(a,b,c)}$と電流$i_{L(a,b,c)}=i_{o(a,b,c)}$の平均化方程式を示している。

$$\langle u_{La}\rangle = d_A\langle u_{in}\rangle - r_{eq}\langle i_{La}\rangle - \langle u_{an}\rangle - \langle u_{nN}\rangle \quad (1)$$

$$\langle u_{Lb}\rangle = d_B\langle u_{in}\rangle - r_{eq}\langle i_{Lb}\rangle - \langle u_{bn}\rangle - \langle u_{nN}\rangle \quad (2)$$

$$\langle u_{Lc}\rangle = d_B\langle u_{in}\rangle - r_{eq}\langle i_{Lc}\rangle - \langle u_{cn}\rangle - \langle u_{nN}\rangle \quad (3)$$

$$\langle i_{oa}\rangle = \langle i_{La}\rangle \quad (4)$$

$$\langle i_{ob}\rangle = \langle i_{Lb}\rangle \quad (5)$$

$$\langle i_{oc}\rangle = \langle i_{Lc}\rangle \quad (6)$$

上記の関係式の山括弧は平均値を表し、$r_{eq}=r_{sw}+r_L$ であり、$r_L=r_{L(a,b,c)}$ である。等価抵抗には、オン状態のスイッチ抵抗（r_{sw}）とインダクタの抵抗（r_L）の両方が含まれる,。さらに、$d_{A,B,C}$ はデューティ比を表す。空間ベクトル理論により、式(7)に示すように、$3-\phi$ 変数 $x_{a,b,c}(t)$ を単一の複素数値 $x_{\alpha,\beta}(t)$ に変換できる。

$$x(t)=\frac{2}{3}\left(x_a(t)e^{j0}+x_b(t)e^{j2\pi/3}+x_c(t)e^{j4\pi/3}\right)=|x(t)|e^{j\phi}=x_\alpha(t)+jx_\beta(t) \quad (7)$$

変換に2/3を掛けることで、空間ベクトルの大きさが平衡・対称な $3-\phi$ システムにおける変数の最大値に等しくなる,。
(1)に $\frac{2}{3}e^{j0}$ を、(2)に $\frac{2}{3}e^{j2\pi/3}$ を、(3)に $\frac{2}{3}e^{j4\pi/3}$ を掛け、(7)を用いてそれらを足し合わせる。

$$\langle \mathbf{u}_L\rangle = \mathbf{d}\langle u_{in}\rangle - r_{eq}\langle \mathbf{i}_L\rangle - \langle \mathbf{u}_0\rangle - \langle u_{nN}\rangle - \frac{2}{3}(e^{j0}+e^{j2\pi/3}+e^{j4\pi/3})\langle u_{nN}\rangle \quad (8a)$$

$$\langle \mathbf{u}_L \rangle = \mathbf{d}\langle u_{in} \rangle - r_{eq}\langle \mathbf{i}_L \rangle - \langle \mathbf{u}_0 \rangle \quad (8b)$$

ここで $(e^{j0} + e^{j2\pi/3} + e^{j4\pi/3} = 0)$ である。式(8b)は静止座標系（$\alpha - \beta$）における平均化方程式を表している。式8(b)を書き直すと(9)が得られる。

$$\frac{d\langle \mathbf{i}_L \rangle}{dt} = \frac{1}{\mathbf{L}}[\mathbf{d}\langle u_{in} \rangle - r_{eq}\langle \mathbf{i}_L \rangle - \langle \mathbf{u}_0 \rangle] \quad (9)$$

ここで、$\mathbf{L} = L_{abc}$、$\mathbf{d} = \frac{2}{3}(d_A e^{j0} + d_B e^{j2\pi/3} + d_C e^{j4\pi/3})$、$\langle \mathbf{i}_L \rangle = \frac{2}{3}(\langle i_{La} \rangle e^{j0} + \langle i_{Lb} \rangle e^{j2\pi/3} + \langle i_{Lc} \rangle e^{j4\pi/3})$、$\langle \mathbf{u}_0 \rangle = \frac{2}{3}(\langle u_{an} \rangle e^{j0} + \langle u_{bn} \rangle e^{j2\pi/3} + \langle u_{cn} \rangle e^{j4\pi/3})$ である。

三相変数が静止座標系（$\alpha - \beta$）に変換されると、これらの空間ベクトルはさらに同期回転座標系（d-q）に変換される,。この交流量から定数直流量への変換は、パワーエレクトロニクス変換器の定常（SS）安定性解析において有利であることがわかる。式(11)は、同期回転座標系（SRF）における空間ベクトルを表し、d-qの下付き文字は実部と虚部のコンポーネントを示す。

$$x^s(t) = x(t)e^{-j\omega_s t} = x_d + jx_q \quad (11)$$

(11)において、ω_sは系統周波数を表し、上付き文字は同期回転座標系を示す。式(11)を用いて式(9)を同期（d-q）座標系に変換する：

$$\frac{d(\langle i_L^s \rangle e^{j\omega_s t})}{dt} = \frac{1}{L}\left(d^s\langle u_{in} \rangle e^{j\omega_s t} - (r_{eq} + j\omega_s L)\langle i_L^s \rangle e^{j\omega_s t} - \frac{1}{L}\langle u_0^s \rangle e^{j\omega_s t}\right) \quad (12)$$

結果として、式(12)から式(13)を次のように導出した,。

$$\frac{d\langle i_L^s \rangle}{dt} = \frac{1}{L}\left(d^s\langle u_{in} \rangle - (r_{eq} + j\omega_s L)\langle i_L^s \rangle - \langle u_0^s \rangle\right) \quad (13)$$

$$\frac{d\langle i_{Ld} + ji_{Lq} \rangle}{dt} = \frac{1}{L}\left[(d_d + jd_q)\langle u_{in} \rangle - (r_{eq} + j\omega_s L)\langle i_{Ld} + ji_{Lq} \rangle - \langle u_{od} + ju_{oq} \rangle\right] \quad (14)$$

最後に、(14)をd軸成分とq軸成分に分離する。

$$\frac{d\langle i_{Ld} \rangle}{dt} = \frac{1}{L}[d_d\langle u_{in} \rangle - r_{eq}\langle i_{Ld} \rangle + \omega_s L\langle i_{Lq} \rangle - \langle u_{od} \rangle] \quad (15)$$

$$\frac{d\langle i_{Lq} \rangle}{dt} = \frac{1}{L}[d_q\langle u_{in} \rangle - r_{eq}\langle i_{Lq} \rangle - \omega_s L\langle i_{Ld} \rangle - \langle u_{oq} \rangle] \quad (16)$$

$$\langle i_{od} \rangle = \langle i_{Ld} \rangle \quad (17)$$

$$\langle i_{oq} \rangle = \langle i_{Lq} \rangle \quad (18)$$

式(15)〜(18)は、SRFにおけるインバータの大信号モデルを構成する。選択された系統電圧方向制御の制御アプローチでは、d軸をインバータの出力電圧空間ベクトルに合わせることが極めて重要である,。これにより、有効電力はd軸電流によって排他的に決定され、q軸成分が無効電力を決定することが保証されるためである。さらに、変換器の力率1での動作を維持するために、qチャネルの系統電流および電圧の定常（SS）値はゼロでなければならない。これらの条件下では、インバータは有効電力のみを系統に注入する。

$$P = U_{od} I_{Ld} \quad (19)$$

式(19)は、有効電力のみが系統に供給されることを意味している。VSIの大信号平均モデル方程式は非線形項を含んでいる,。線形モデルを開発するには、事前定義された動作点を中心とする小信号方程式の導出が必要である。

$$\frac{d\hat{i}_{Ld}}{dt} = \frac{1}{L}[\hat{d}_d U_{in} + D_d \hat{u}_{in} - r_{eq}\hat{i}_{Lq} + \omega_s L \hat{i}_{Ld} - \hat{u}_{od}] \quad (20)$$

$$\frac{d\hat{i}_{Lq}}{dt} = \frac{1}{L}[\hat{d}_q U_{in} + D_q \hat{u}_{in} - r_{eq}\hat{i}_{Lq} - \omega_s L \hat{i}_{Ld} - \hat{u}_{oq}] \quad (21)$$

$$\hat{i}_{od} = \hat{i}_{Lq} \quad (22)$$

$$\hat{i}_{oq} = \hat{i}_{Lq} \quad (23)$$

(20)〜(23)は、SS動作点を中心とした小信号方程式を表現している。

$$\frac{d\hat{\mathbf{x}}(t)}{dt} = A\hat{\mathbf{x}}(t) + B\hat{\mathbf{u}}(t)$$

$$\hat{\mathbf{y}}(t) = C\hat{\mathbf{x}}(t) + D\hat{\mathbf{u}}(t) \quad (24)$$

式(24)は状態空間方程式を示している。

$$\hat{\mathbf{x}}(t) = [\hat{i}_{Ld} \quad \hat{i}_{Lq}]^T \quad (25)$$

$$\hat{\mathbf{u}}(t) = [\hat{u}_{in} \quad \hat{u}_{od} \quad \hat{u}_{oq} \quad \hat{d}_d \quad \hat{d}_q]^T \quad (26)$$

$$\hat{\mathbf{y}}(t) = [\hat{i}_{od} \quad \hat{i}_{oq}]^T \quad (27)$$

(25)、(26)、および(27)はそれぞれシステムの状態ベクトル、入力ベクトル、出力ベクトルを表している。状態行列A、B、C、Dは(20)〜(23)から次のように得られる。

$$A = \begin{bmatrix} -\frac{r_{eq}}{L} & \omega_s \\ -\omega_s & -\frac{r_{eq}}{L} \end{bmatrix}, \quad B = \begin{bmatrix} \frac{D_d}{L} & -\frac{1}{L} & 0 & -\frac{U_{in}}{L} & 0 \\ \frac{D_q}{L} & 0 & -\frac{1}{L} & 0 & -\frac{U_{in}}{L} \end{bmatrix}$$

,

$$C = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad D = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

III. INTRODUCTION TO RL（強化学習の導入）

強化学習（RL）は、マルコフ決定過程（MDP）の枠組みの中で動作するアルゴリズムである。MDPにおいて、次の時間ステップにおける状態は現在の状態のみによって決定され、過去の状態には依存せず、環境は完全に観測可能である。エージェントには、観測と報酬が提供され、これらは事前に定義された関数に基づいて生成され、その入力として機能する,。

A. Observation（観測）

観測モジュールは、図2に示すように環境から観測値o_tを取得し、それをエージェントに転送する。本論文において、観測モジュールは $[i_d, i_q, i_{dref}, i_{qref}]^T$ であり、ここで i_d, i_q は時間tにおける出力電流のdq軸に沿った成分であり、i_{dref}, i_{qref} はdq軸に沿った出力電流の基準値である。

B. Reward（報酬）

RLの中心となる原則は、アクションを評価するための基本的な指標として機能する、最大の報酬を目指すことである。ゼロ電流追従誤差の達成を強化し、インバータの動的応答の感度を高めるために、インバータの報酬関数が式(30)として次のように定式化されている,。

$$r = -(p_1 i_{derror}^2 + p_2 i_{qerror}^2 + p_3 \sum (u_{t-1})^2) \quad (30)$$

ここで、u_{t-1} は前のステップからのアクションであり、p_1, p_2, p_3 は重み付け係数を表す。これらの係数を調整することで報酬関数を改良し、インバータの実際の性能状況をより正確に反映させることができる。報酬は、タスクの目標を達成する上で、（前の状態から取られた）先行するアクションの成功の即時的な尺度として機能する。

C. Agent（エージェント）

エージェントは2つの主要なコンポーネントで構成される。現在の観測を可能なアクションの確率分布にマッピングする役割を担う「方策（ポリシー）」と、学習アルゴリズムである,。学習アルゴリズムは、タスクの期間全体にわたって期待される最大の合計報酬を最適化する最も有利な方策を特定することを目的として、方策のパラメータを反復的に調整する。RLエージェントのトレーニングには、報酬とペナルティ（罰）が用いられる。図3はMATLAB/Simulinkにおける報酬関数の実装を示しており、エージェントは良い決定を下した場合には報酬を受け取り、悪い決定を下した場合にはペナルティを課される,。

IV. DDPG ALGORITHM（DDPGアルゴリズム）

RL-DDPGアルゴリズムは、モデルを必要とせず、オンラインで動作するオフポリシーのアクター・クリティックベースの学習手法である。アクター・クリティックRLエージェントとして機能するDDPGエージェントは、期待される合計報酬を最大化する最も有利な方策を発見することを目指す。

A. Actor-Critic（アクター・クリティック）

DDPGアルゴリズムは、深層学習技術とアクター・クリティックアーキテクチャを活用して、決定論的な方策を確立する。このアルゴリズムでは、クリティックとアクターの両方が関数近似に深層ニューラルネットワークを利用する,。DDPGは、方策ベースの手法と価値ベースの手法の両方の利点を融合させている。アクターはアクションを選択し、クリティックはアクションの質を評価して調整をアドバイスする。クリティックは価値関数を評価し、これは行動価値または状態価値のいずれかに関連する可能性がある。アクターは、クリティックネットワークによって提供される出力値に従って方策を更新する。

B. Configuration of the Neural Network (NN)（ニューラルネットワークの構成）

エージェントの収束速度は、ディープNNのアーキテクチャに大きく影響される。したがって、トレーニング中に適切なニューラルネットワーク構造を選択することは極めて重要である。それはトレーニングプロセスに影響を与え、結果が目標から逸脱する原因となる可能性があるためである,。図4は、アクターとクリティック両方のディープNNの構成を示している。このネットワークで採用されている正規化線形関数（ReLU）の活性化関数は、非線形である。これは負の値を実質的にゼロに置き換え、ネットワークが複雑なパターンを理解し、トレーニング中の収束を強化することを可能にする。特定のニューロンの出力をゼロにすることで、ReLU関数は効果的にパラメータの依存性を減らし、過学習の発生を軽減する,。

V. SIMULATION VERIFICATION（シミュレーション検証）

RL-DDPG制御器の有効性を評価するために、$3-\phi$（三相）インバータをSimulink上に構築した。さらに、比較分析のためにインバータを制御する従来のPI制御器を採用している,。具体的なシミュレーションパラメータは表1に示されている,。図5は、DDPGアルゴリズムの最終的なトレーニング結果を示している。エージェントのトレーニングプロセスにおいて、水色の線は実際の報酬（エピソード報酬）を示し、濃い青色の線は平均報酬を描き、黄色の線は各エピソードの開始時における割引長期報酬の推定値（エピソードQ0）を示している。トレーニングが進むにつれて、クリティックが効果的に設計され、効率的に学習していれば、割引による潜在的な不一致があるにもかかわらず、エピソードQ0は真の割引長期報酬の平均に徐々に収束していく,。

このトレーニングシナリオでは、終了報酬は900に設定されている。250回目のトレーニングエピソードまでに終了条件が満たされていることは明らかである。さらに、報酬は500回目のトレーニングエピソードまで安定しており、エージェントが目標を達成したことを示している。比較を容易にするため、2つの制御器の結果を表IIにまとめている。

図6は、RLによって制御されるVSIが生成する負荷電流のTHDが、PIによって制御されるものよりも47%低いことを示している,。動的性能において、PI制御器とRL-DDPG制御器の整定時間（セトリングタイム）はほぼ同じである。しかし、図7に示すように、PI制御器におけるオーバーシュートはRL-DDPG制御器よりも大きい。PI制御器は定常状態に達するまでにより多くのサイクルを必要とし、負荷電流のリプルも確認できる。さらに、過渡期間中、図8に示される負荷電流波形は、RL-DDPG制御器よりもPI制御器の方が大きく変動する。PI制御器は多くの場合、動的性能を犠牲にして定常性能を向上させるか、あるいはその逆を行うが、RL-DDPG制御はニューラルネットワークを通じてインバータの適切な非線形制御を達成するようにトレーニングされており、最終的に動的および定常運転の両方において優れた性能をもたらす,。

VI. CONCLUSION（結論）

本論文は、RL負荷を持つ $3-\phi$（三相）VSIを制御するためのRL-DDPGアルゴリズムに基づく制御器を導入した。従来のPI制御手法と比較して、提案する制御アルゴリズムはシステムモデルに依存せず、RLにおけるモデルフリーのトレーニングの特性を活用している。DDPGアルゴリズムベースの制御器は、定常状態および動的状態の両方で良好に機能する。しかし、深層ニューラルネットワークが存在するため、モデルのトレーニングに一定の時間を要する。さらに、システムの性能は報酬関数に依存するため、報酬関数の構築はRL-DDPG制御の極めて重要な部分である。